Report

Part 1:

Part 1.0 – EDA-1

- Describe how the dataset are cleaned and prepared.

  ตอบ เริ่มต้นด้วยการนำเข้า Dataset_A(worldbank_gender_2021.csv) และ Dataset_B(countries_regions.xlsx) มาเป็นตาราง 1 และ 2 ตามลำดับ จากนั้นจึงตรวจสอบขนาดของตารางทั้งสอง พบว่ามีขนาด column ที่ไม่เท่ากัน จึงทำการตรวจสอบรายละเอียดของทั้งสองตาราง โดยทั้งสองตารางมีชื่อประเทศ ที่ไม่ตรงกันทั้งสิ้น 3 ประเทศ โดยเป็นการใช้ชื่อที่ต่างกัน 2 ชื่อ และใช้ชื่อที่ไม่พบในอีกตาราง 1 ชื่อ จึงทำการแก้ไขชื่อของตารางที่ 1 ให้ตรงกับตารางที่ 2 แล้วจึงรวมตารางด้วยวิธี merge แบบ inner เพื่อให้อีกชื่อที่ไม่ตรงไม่อยู่ในตารางรวม ต่อมาเมื่อทำการตรวจสอบค่าที่หายไปของ ตารางรวมพบว่า มีราว 80 column ที่มีค่าที่หายไปเกิน 50 % ของทั้งหมด จึงทำการ drop column เหล่านั้นไป อีกทั้งเมื่อทำการตรวจสอบ correlation ระหว่างแต่ละ column พบว่ามีถึง 21 คู่ที่มี correlation เกิน 0.9 และได้ทำการตรวจสอบเพิ่มเติมโดยการทำ normality test พบว่ามีเพียง 2 column เท่านั้นที่ผ่าน จึงจะเก็บข้อมูลของ correlation และ normality นี้ไว้สำหรับการออกแบบ แต่ละ workflow ต่อไป

Part 1.1 – Modelling-1

- For each workflow, write a summary that explains:

  I. Your preprocessing choices: Why you choose these preprocessing choices and how they help performance improvement.

  II. Your feature subset selection: Why these features are chosen and how feature reduction affects the model.

  III. Your modelling choice: Why this model is selected, and how model (or the combination of i)-iii)) helps with performance improvement.

Workflow 1:

I.) ตอบ

- ทำการ drop column ‘Country Name' ทิ้งเพราะเป็นข้อมูล สำหรับการบอกลำดับข้อมูลซึ่งไม่ค่อยส่งผลต่อค่าที่ต้องการจะทำนาย
- ใช้ train_test_split แบ่งชุดข้อมูลเป็น 2 ส่วนป้องกัน การ overfit ของโมเดล
- เติมข้อมูลส่วนที่ขาดหายไปในชุดข้อมูลตัวเลขด้วยค่า median เพื่อกำจัดค่าที่หายไปทั้งหมดและแทนด้วยค่ากลางที่เหมาะสมสำหรับ ข้อมูลที่ไม่ได้มีการกระจายตัวแบบปกติ
- หา outlier ด้วยเกณฑ์ percentile ที่ 5 และ 95 แล้วแทนที่ด้วยการ clipping เพื่อลดผลกระทบของค่าข้อมูลที่ไม่อยู่ในกลุ่มส่วนใหญ่
- encoding ข้อมูลชนิด categorical โดยใช้ label encoding เพื่อแปลงข้อมูลให้สามารถใช้ประมวลผลได้
- scaling ข้อมูลชนิด numerical ด้วย standard scaling เพื่อลด bias ในโมเดล

II.) ตอบ

- ใช้การกรองเบื้องต้นด้วย correlation โดยหากคู่ของ column ใดมี correlation เกิน 0.9 จะทำการคัด 1 column ของคู่นั้น ๆ ออกจากโมเดล
- ใช้ forward selection ในการกรอง column โดยเลือกเฉพาะ column ที่คะแนนอยู่ใน 25 อันดับแรกให้อยู่ใน model

III) ตอบ

- เลือกใช้โมเดล Decision Tree เพราะง่ายต่อการแปลความและหาความสำคัญของ feature สำหรับใช้พัฒนาใน Work flow ถัด ๆ ไป

Workflow 2:

I) ตอบ

- ทำการ drop column ‘Country Name' ทิ้งเพราะเป็นข้อมูล สำหรับการบอกลำดับข้อมูลซึ่งไม่ค่อยส่งผลต่อค่าที่ต้องการจะทำนาย
- ใช้ train_test_split แบ่งชุดข้อมูลเป็น 2 ส่วนป้องกัน การ overfit ของโมเดล
- เติมข้อมูลส่วนที่ขาดหายไปในชุดข้อมูลตัวเลขด้วยค่า mean ของ column นั้นๆ เพื่อกำจัดค่าที่หายไปทั้งหมดและแทนด้วยค่ากลาง
- หา outlier ด้วยเกณฑ์ percentile ที่ 1 และ 99 แล้วแทนที่ด้วยการ clipping เพื่อลดผลกระทบของค่าข้อมูลที่ไม่อยู่ในกลุ่มส่วนใหญ่
- encoding ข้อมูลชนิด categorical โดยใช้ label encoding เพื่อแปลงข้อมูลให้สามารถใช้ประมวลผลได้

- scaling ข้อมูลชนิด numerical ด้วย standard scaling เพื่อลด bias ในโมเดล

II.) ตอบ

- ใช้การกรองเบื้องต้นด้วย correlation โดยหากคู่ของ column ใดมี correlation เกิน 0.9 จะทำการคัด 1 column ของคู่นั้น ๆ ออกจากโมเดล

III) ตอบ

- เลือกใช้โมเดล K-Nearest Neighbor ด้วยค่า K = 5 และ การคำนวณระยะทางแบบ Manhattan เพราะช่วยในการเพิ่มประสิทธิภาพของโมเดลโดยเฉพาะในกรณีที่ข้อมูลอาจไม่เป็น Linear และมี Feature ที่ค่อนข้างกระจายตัว

Workflow 3:

I.) ตอบ

- ทำการ drop column ‘Country Name' ทิ้งเพราะเป็นข้อมูล สำหรับการบอกลำดับข้อมูลซึ่งไม่ค่อยส่งผลต่อค่าที่ต้องการจะทำนาย
- ใช้ train_test_split แบ่งชุดข้อมูลเป็น 2 ส่วนป้องกัน การ overfit ของโมเดล
- เติมข้อมูลส่วนที่ขาดหายไปในชุดข้อมูลตัวเลขด้วยค่า median เพื่อกำจัดค่าที่หายไปทั้งหมด และแทนด้วยค่ากลางที่เหมาะสมสำหรับ ข้อมูลที่ไม่ได้มีการกระจายตัวแบบปกติ
- หา outlier ด้วยเกณฑ์ percentile ที่ 1 และ 99 แล้วแทนที่ด้วยการ clipping เพื่อลดผลกระทบของค่าข้อมูลที่ไม่อยู่ในกลุ่มส่วนใหญ่
- encoding ข้อมูลชนิด categorical โดยใช้ label encoding เพื่อแปลงข้อมูลให้สามารถใช้ประมวลผลได้
- scaling ข้อมูลชนิด numerical ด้วย standard scaling เพื่อลด bias ในโมเดล

II.) ตอบ

- ใช้การกรองเบื้องต้นด้วย correlation โดยหากคู่ของ column ใดมี correlation เกิน 0.9 จะทำการคัด 1 column ของคู่นั้น ๆ ออกจากโมเดล
- ใช้ Recursive Feature Elimination ในการกรอง column โดยเลือกเฉพาะ column ที่คะแนนอยู่ใน 20 อันดับแรกให้อยู่ใน model

III) ตอบ

- เลือกใช้โมเดล Random Forest เพราะคาดเดาว่า โมเดลก่อนหน้าอาจผิดพลาดจากค่า Noise ที่ไม่เกี่ยวข้องจึงทำการใช้ โมเดลนี้เพื่อเพิ่มความทนทานต่อ Noise ที่มีในข้อมูล

- Result interpretation

1. Based on your last workflow, discuss the performance of your final model. Justify whether the performance is good or not.

   ตอบ โมเดลสุดท้ายได้ผลลัพธ์ของประสิทธิภาพดังนี้

   Accuracy: 0.473684

   F1-Score: 0.485201

   Confusion Matrix:

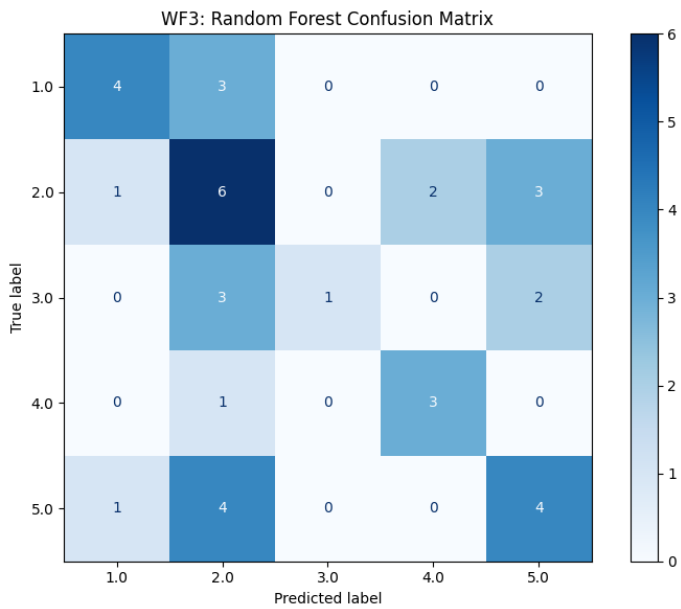

   ผลลัพธ์มี Accuracy และ F1-Score ที่สูงกว่าการเดาสุ่ม(0.2) ที่ราว 140 % ซึ่งถือว่าอยู่ในเกณฑ์ที่ดี แต่ก็ยังมีช่องว่างสำหรับการพัฒนาโดยเมื่อดูที่ Confusion Matrix พบว่า class ที่ 3 และ 5 ตัวโมเดลทำนายพลาดเยอะกว่าทำนายถูกอยู่ซึ่งเป็นผลมาจากแหล่งข้อมูลที่น้อยเกินไป และความไม่สมดุลของข้อมูลส่งผลให้โมเดลเกิดความสับสน โดยเฉพาะระหว่าง Class ที่มีลักษณะใกล้เคียงกัน เช่น การทำนายผิดจาก Class 3 ไปเป็น Class 2 เป็นต้น

2. Interpret the final model. For example, which variables significantly affect the model and which variables significantly affect the Gender Ratio class.

   ตอบ จากผลลัพธ์ของ feature importance จากตัวโมเดลบ่งบอกถึง 5 feature ที่ส่งผลต่อโมเดลมากที่สุดคือ

   1. Rural population (0.0785)

   2. GDP growth (0.0574

3. Medium/high-tech manufacturing value added (0.0560)
4. Price level ratio (0.05513
5. Cereal yield (0.05445)

3. Apply Analysis of variance to describe whether Regions (in dataset2) affects the Gender Ratio class.
   ตอบ จากการใช้ ANOVA test ที่ alpha = 0.05 ได้ข้อสรุปว่า Regions ส่งผลต่อ Gender Ratio class จริง
4. Apply Analysis of Categorical data to describe whether the Gender Ratio class is independent of Regions (in dataset2).
   ตอบ จากการใช้ chi-square test ที่ alpha = 0.05 ได้ข้อสรุปว่า Gender Ratio class ไม่ได้เป็นอิสระต่อ Regions

Part 1.2 – Feature Extraction

- Report which methods that you use.
  ตอบ ใช้ 2 วิธีการคือ PCA (Principal Component Analysis) และ LDA (Linear Discriminant Analysis)
- Describe the number of components/discriminants/factors that you finally choose to represent the majority of data.
  ตอบ
  สำหรับ PCA จะเลือกจากจำนวนแกน ที่ครอบคลุม 95 % ของ variance ทั้งหมดของข้อมูลซึ่งต้องใช้ทั้งสิ้น 45 แกน
  ในส่วนของ LDA เลือกใช้จำนวนแกน ทั้งสิ้น 4 แกน เนื่องจากเป็นจำนวนแกนที่น้อยที่สุดที่สามารถแบ่งแยก Class ครบทั้ง 5 ตามจุดประสงค์ของโมเดล
- Describe how components/discriminants/factors relate to the original variables
  ตอบ
  PCA: เนื่องจากใช้จำนวนแกนมากถึง 45 แกน จึงขอเลือก 4 แกนแรกที่สำคัญที่สุด มาอธิบาย
  PC1: แกนนี้จะอธิบายถึงตัวแปรที่แสดงถึงจำนวนคนช่วงวัยเด็กเป็นหลัก
  Population ages 0-14 (% of total population): 0.1804
  Birth rate, crude (per 1,000 people): 0.1800
  Life expectancy at birth, female (years): -0.1765
  PC2: แกนนี้อธิบายถึงตัวแปรของจำนวนประชากรในแต่ละประเภทเป็นหลัก
  Population, total: 0.2761

Labor force, total: 0.2738

Urban population: 0.2723

PC3: แกนนี้อธิบายถึงตัวแปรของอัตราส่วนของแรงงานผู้หญิงและอัตราการเกิดโรค-การตายป็นหลัก

Labor force, female (% of total labor force): 0.2909

Death rate, crude (per 1,000 people): 0.2307

Diabetes prevalence (% of population ages 20 to 79): -0.2218

PC4: แกนนี้อธิบายถึงตัวแปรของพื้นที่ประเภทต่าง ๆ ภายในประเทศเป็นหลัก

Arable land (% of land area): 0.2655

Permanent cropland (% of land area): 0.2509

Forest area (sq. km): -0.2076

LDA:

LD1: แกนนี้อธิบายถึงอายุเฉลี่ยก่อนตายของเพศชายและ พื้นที่ของประเทศเป็นหลัก

Life expectancy at birth, total (years): -15.7905

Life expectancy at birth, male (years): 8.1376

Surface area (sq. km): -6.7842

LD2: แกนนี้อธิบายถึงอายุเฉลี่ยก่อนตายของเพศหญิงและ พื้นที่ของประเทศเป็นหลัก

Life expectancy at birth, total (years): 26.5585

Life expectancy at birth, female (years): -15.4109

Surface area (sq. km): -13.4249

LD3: แกนนี้อธิบายถึงอายุเฉลี่ยก่อนตายของประชากรและ พื้นที่ของประเทศเป็นหลัก

Life expectancy at birth, total (years): 50.5875

Surface area (sq. km): 32.1980

Land area (sq. km): -31.1959

LD4: แกนนี้อธิบายถึงจำนวนคนในวัยทำงานและ พื้นที่ของประเทศเป็นหลัก

Age dependency ratio (% of working-age population): 8.4274

Land area (sq. km): 7.8674

Surface area (sq. km): -7.3821

Part 2:

Part 2.0: EDA-2

- Describe how the dataset are cleaned and prepared.

  ตอบ

เริ่มต้นด้วยการนำเข้า Dataset_C (worldbank_2017_2021) และ Dataset_B (countries_regions.xlsx) มาเป็นตารางที่ 1 และตารางที่ 2 ตามลำดับ จากนั้นทำการตรวจสอบขนาดของตารางทั้งสอง พบว่าจำนวน column ของตารางไม่เท่ากัน จึงดำเนินการตรวจสอบรายละเอียดเพิ่มเติม พบว่าทั้งสองตารางมีชื่อประเทศที่ไม่ตรงกันทั้งหมด 3 ประเทศ โดยแบ่งเป็นกรณีที่ใช้ชื่อประเทศต่างกัน 2 ประเทศ และกรณีที่ชื่อประเทศไม่ปรากฏในอีกตารางหนึ่ง 1 ประเทศ จึงทำการปรับแก้ชื่อประเทศในตารางที่ 1 ให้ตรงกับตารางที่ 2

ต่อมาได้ตรวจสอบค่าที่หายไป ในตารางที่ 1 พบว่ามีประมาณ 76 คอลัมน์ที่มีค่าที่หายไปมากกว่า 50% จึงทำการ drop column เหล่านั้นออก จากนั้นเติมค่าที่หายไปใน column ที่เหลือด้วยค่า median อย่างไรก็ตาม ยังพบว่าข้อมูลของแต่ละประเทศประกอบด้วยข้อมูลรายปีจำนวน 5 ปี (ตั้งแต่ปี 2017–2021) ดังนั้นสำหรับข้อ 2.1 ที่ต้องการจัดกลุ่มตามชื่อประเทศ จึงทำการรวมแถวของแต่ละประเทศให้เหลือเพียง 1 แถว โดยใช้ค่าเฉลี่ยของข้อมูลทั้ง 5 ปีในแต่ละ column ส่วนในข้อ 2.2 จะไม่มีการรวมแถวของแต่ละประเทศเนื่องจาก เป้าหมายของโมเดลคือการคำนายค่าจึงควรใช้ข้อมูลทั้งหมดดังเดิม

หลังจากนั้นจึงทำการรวมตารางที่ 1 กับตารางที่ 2 ด้วยวิธี inner merge เพื่อให้ชื่อประเทศที่ไม่ตรงกันถูกตัดออกจากตารางรวม สุดท้ายได้ตรวจสอบ correlation ระหว่าง column ต่าง ๆ พบว่ามี 19 คู่ที่มีค่า correlation มากกว่า 0.9 จึงทำการตรวจสอบเพิ่มเติมด้วยการ normality test ซึ่งพบว่ามีเพียง 13 คอลัมน์ที่ผ่านเกณฑ์การทดสอบ โดยข้อมูลด้าน correlation และ normality เหล่านี้จะถูกเก็บไว้เพื่อใช้ในการออกแบบ workflow ในขั้นตอนถัดไป

Part 2.1: Clustering

- Report which method that you use and performance evaluation.

  ตอบ ใช้วิธี K-Means โดยได้ผลลัพธ์ดังนี้

  Silhouette Index: 0.6775380868868375

  Davies-Bouldin Index: 0.407516079936867

  Dunn Index: 0.6895119777501192

  CH Index: 1987.158663928231

- Describe the number of clusters you finally obtained and how you determine to clusters

  ตอบได้จำนวน clusters ทั้งหมด 5 กลุ่ม เลือกโดยใช้วิธีการ elbow method และ เปรียบเทียบ Silhouette Index

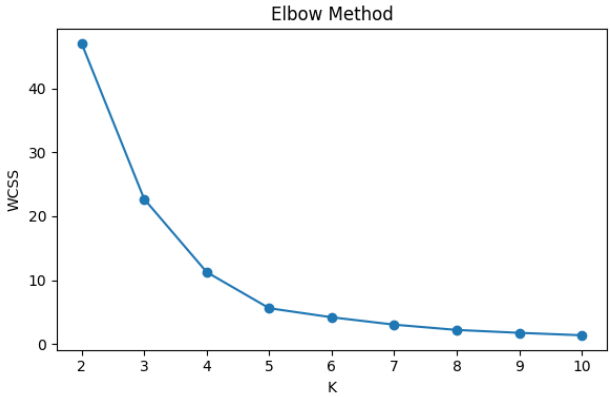

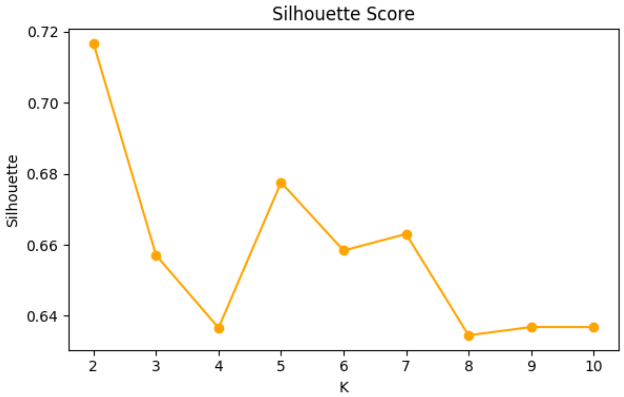

จากกราฟได้ว่า จุดหักของกราฟอยู่ที่ 5 cluster และ เมื่อ ใช้เปรียบเทียบกับ Silhouette Index ก็พบว่า ที่ 5 cluster ให้ผลลัพธ์สูงเช่นกัน จึงเลือกใช้ 5 cluster ในท้ายที่สุด

- Can you describe the characteristics of countries in each cluster? What are common characteristics that countries inside the same cluster share? What are the characteristic differences between different clusters?

ตอบ จากการวิเคราะห์กราฟ Radar Chart และ Box Plots สามารถสรุปลักษณะเด่นของแต่ละ Cluster ได้ดังนี้

ลักษณะเฉพาะของแต่ละ Cluster

Cluster 0: กลุ่มประเทศเน้นเกษตรกรรม

ลักษณะเด่น: เป็นกลุ่มที่มีความแตกต่างจากกลุ่มอื่นชัดเจนที่สุด โดยมีสัดส่วนภาคการเกษตรต่อ GDP สูงที่สุด และมีสัดส่วนประชากรวัยเด็ก (0-14 ปี) สูงที่สุดที่ราว 40%

Cluster 1: กลุ่มประเทศพัฒนาแล้ว

ลักษณะเด่น: มี Fixed broadband subscriptions, Fixed telephone subscriptions สูงและ

อัตราการตายของเด็กที่ต่ำแสดงถึงความก้าวหน้าของการแพทย์

Cluster 2: กลุ่มประเทศกำลังพัฒนา

ลักษณะเด่น: เป็นกลุ่มที่อยู่ตรงกลาง ในเกือบทุกด้าน มีการพึ่งพาเกษตรกรรมลดลงมาจาก Cluster 0 และมีสัดส่วนประชากรเด็กปานกลาง

Cluster 3: กลุ่มประเทศกำลังพัฒนาค่อนไปทางพัฒนาแล้ว

ลักษณะเด่น: เป็นกลุ่มที่มีการพัฒนาดีกว่า Cluster 2 โดยดูที่ Fixed broadband subscriptions ที่ดีขึ้น และอัตราการเสียชีวิตของเด็กต่ำลง

Cluster 4: กลุ่มประเทศพัฒนาแล้ว

ลักษณะเด่น: คล้ายคลึงกับ Cluster มากแต่จะมีความเจริญของการแพทย์ที่ดีกว่าเล็กน้อย

Part 2.2 – Modelling-2

- For each workflow, write a summary that explains:
    I. Your preprocessing choices: Why you choose these preprocessing choices and how they help performance improvement.
    II. Your feature subset selection: Why these features are chosen and how feature reduction affects the model.
    III. Your modelling choice: Why this model is selected, and how model (or the combination of i)-iii)) helps with performance improvement.

Workflow 1:

I.) ตอบ

- แบ่งข้อมูลเป็นสองส่วน คือส่วนที่ใช้ train จะป็นข้อมูลทั้งหมดตั้งแต่ปี 2017 – 2020 และ ส่วนที่ใช้ test จะเป็นข้อมูลในปี 2021 เพื่อให้สัดส่วนของ ข้อมูล train และ test เท่ากันป้องกันการเกิด bias ของข้อมูล
- เติมข้อมูลส่วนที่ขาดหายไปในชุดข้อมูลตัวเลขด้วยค่า median เพื่อกำจัดค่าที่หายไปทั้งหมดและแทนด้วยค่ากลางที่เหมาะสมสำหรับ ข้อมูลที่ไม่ได้มีการกระจายตัวแบบปกติ
- หา outlier ด้วยเกณฑ์ percentile ที่ 1 และ 99 แล้วแทนที่ด้วยการ clipping เพื่อลดผลกระทบของค่าข้อมูลที่ไม่อยู่ในกลุ่มส่วนใหญ่
- ใช้เฉพาะข้อมูลชนิด numerical ในการสร้างmodel
- scaling ข้อมูลชนิด numerical ด้วย standard scaling เพื่อลด bias ในโมเดล

II.) ตอบ

- ใช้การกรองเบื้องต้นด้วย correlation โดยหากคู่ของ column ใดมี correlation เกิน 0.9 จะทำการคัด 1 column ของคู่นั้น ๆ ออกจากโมเดล
- ใช้ Recursive Feature Elimination ในการกรอง column โดยเลือกเฉพาะ column ที่คะแนนอยู่ใน 40 อันดับแรกให้อยู่ใน model

III) ตอบ

- เลือกใช้โมเดล Linear Regression เพราะเป็นโมเดลพื้นฐานสำหรับดูความสัมพันธ์ของผลลัพธ์โดยคร่าว ๆ

Workflow 2:

I.) ตอบ

- แบ่งข้อมูลเป็นสองส่วน คือส่วนที่ใช้ train จะป็นข้อมูลทั้งหมดตั้งแต่ปี 2017 – 2020 และ ส่วนที่ใช้ test จะเป็นข้อมูลในปี 2021 เพื่อให้สัดส่วนของ ข้อมูล train และ test เท่ากันป้องกันการเกิด bias ของข้อมูล
- เติมข้อมูลส่วนที่ขาดหายไปในชุดข้อมูลตัวเลขด้วยค่า median เพื่อกำจัดค่าที่หายไปทั้งหมดและแทนด้วยค่ากลางที่เหมาะสมสำหรับ ข้อมูลที่ไม่ได้มีการกระจายตัวแบบปกติ
- หา outlier ด้วยเกณฑ์ percentile ที่ 1 และ 99 แล้วแทนที่ด้วยการ clipping เพื่อลดผลกระทบของค่าข้อมูลที่ไม่อยู่ในกลุ่มส่วนใหญ่
- ใช้เฉพาะข้อมูลชนิด numerical ในการสร้างmodel
- scaling ข้อมูลชนิด numerical ด้วย standard scaling เพื่อลด bias ในโมเดล

II.) ตอบ

- ใช้การกรองเบื้องต้นด้วย correlation โดยหากคู่ของ column ใดมี correlation เกิน 0.9 จะทำการคัด 1 column ของคู่นั้น ๆ ออกจากโมเดล
- ใช้ Lasso feature selection คัดเลือกเฉพาะ feature ที่ส่งผลต่อผลลัพธ์

III) ตอบ

- เลือกใช้โมเดล Random Forest Regressor เพราะคาดเดาว่า โมเดลก่อนหน้าอาจผิดพลาดจากค่า Noise ที่ไม่เกี่ยวข้องจึงทำการใช้ โมเดลนี้เพื่อเพิ่มความทนทานต่อ Noise ที่มีในข้อมูล

- Result interpretation

1. Based on your last workflow, discuss the performance of your final model. Justify whether the performance is good or not.

   ตอบ โมเดลได้ผลลัพธ์ดังนี้

   R2: 0.9331810260504957

   RMSE: 5800.716678798999

   MAE: 3404.169879629631

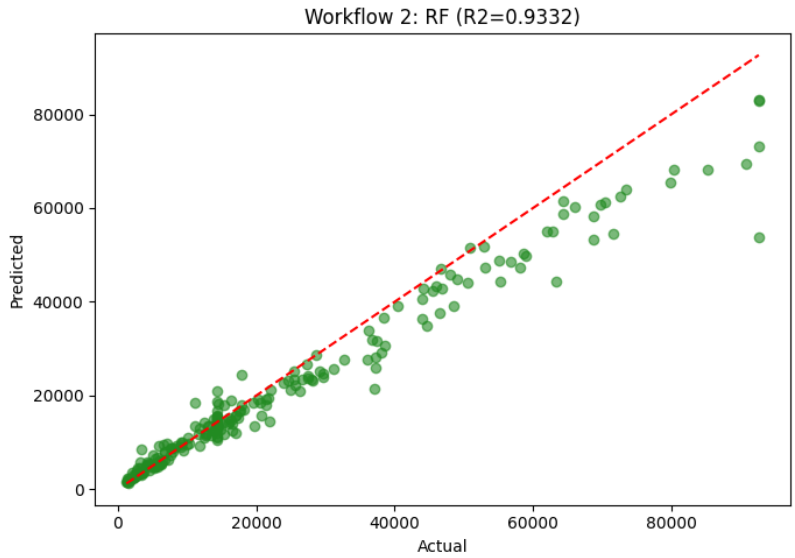

ผลลัพธ์มี R2, RMSE, MAE อยู่ในเกณฑ์ที่ดีแต่ก็ยังมีช่องว่างสำหรับการพัฒนาโดยเมื่อดูที่ กราฟพบว่าเมื่อค่าที่ต้องการทำนายสูงขึ้น โมเดลจะยิ่งให้ผลลัพธ์ที่แย่ลงโดยอาจเป็นผลมมาจากค่า outlier ที่ยังหลงเลหือยู่ภายในข้อมูล

2. Interpret the final model. For example, which variables significantly affect the model and which variables significantly affect the GNI per capita.

   ตอบ จาก feature important ของ โมเดล ได้ 5 ลำดับ feature ที่ส่งผลกระทบมากที่สุดดังนี้

   Life expectancy at birth, male (ค่าเฉลี่ยของช่วงอายุตั้งแต่เกิดของเพศชาย)

   Agriculture, forestry, and fishing (GDP จากการเกษตร)

   Fixed broadband subscriptions (อัตราส่วนคนที่สมัคร internet)

   Vulnerable employment, male (อัตราส่วนคนทำงานเพศชาย)

   Population ages 0-14 (อัตราส่วนประชากรอายุไม่เกิน 14 ปี)

Part 2.3: Dashboard

- Describe the objective of the dashboard (What you would like your dashboard to present.)

  ตอบ ต้องการอธิบายถึงความสัมพันธ์ของค่า GNI โดยรวมของประเทศ รวมไปถึงปัจจัยอื่นที่บ่งบอกถึงการพัฒนาของประเทศได้ เช่นโครงสร้างประชากร,อัตราการลงทะเบียนเรียน,อัตราการเกิดและ,ค่าเฉลี่ยอายุตั้งแต่เกิดจนตายได้

- For each graph in the dashboard, describe the objective of each graph.

  ตอบ

  AVERAGE GNI of each Region in 2021 – กระจายตัวของ GNI ในแต่ละภูมิภาค

Ratio of population age of each country in 2021 – ช่วงอายุของประชากรในแต่ละกลุ่มตัวอย่างของภูมิภาค

GNI vs Average school enrollment in each level – แสดงถึง GNI มีผลต่อการสมัครเรียนในแต่ละระดับอย่างไร

Correlation of Fertility and Life expectancy – แสดงถึงความสัมพันธ์ระหว่างอัตราการเกิดกับเวลาช่วงชีวิตของประชากร

Death rate across year in each country - แสดงถึง อัตราการตายของแต่ละประเทศแตกต่างกันอย่างไร

- Describe narrative visual structure that you use

ตอบ เริ่มต้นที่กราฟ **Average GNI** เพื่อปูพื้นฐานให้เห็นภาพรวมความเหลื่อมล้ำทางเศรษฐกิจโลกและคาดเดาถึงสภาพทางสังคมและเศรษกิจในแต่ละภูมิภาค และนำไปสู่กราฟ Death rate across year in each country เพื่อพิสูจน์ให้เห็นว่าประเทศที่เจริญแล้วมีอัตราการตายน้อยลงจริงตามที่คิด และเพิ่มเติมอีกว่าอัตราการเกิดกับเวลาช่วงชีวิตของประชากรสวนทางกัน ทำให้ส่งผลถึงอัตราส่วนในช่วงอายุของประชากรที่ประเทศพัฒนาแล้วจะมีคนแก่มากกว่าช่วงวัยอื่นอันเป็นผลทำให้ อัตราการลงทะเบียนเรียนของประเทศที่ GNI สูงมาก ไม่ได้เยอะอย่างที่คิด